LAPORAN TUGAS BESAR
DEEP LEARNING

Prakiraan Laju Minyak 30–90 Hari pada Lapangan Volve dengan XGBoost
dan Explainable AI (TreeSHAP) Berbasis Edge AI:
Perbandingan terhadap Decline Curve Analysis Arps

(Kasus 18: Prediksi Produksi dan Analisis Decline Curve Sumur — Production Forecasting & DCA)

Disusun oleh:
Kelompok 3

Raditya Andiza Putro	NPM : 23083010058
Rosyidatul Kamila	NPM : 23083010076
Pinka Nurdiana	NPM : 23083010057
Vivian Subiono	NPM : 23083010065
Nahda Hayu Hemalina	NPM : 23083010066

Dosen Pengampu:
Dr. I Gede Susrama Mas Diyasa, ST., MT.

Dosen Praktisi:
Kahpi Baiquni Arifani, S.Kom., M.Kom.

PROGRAM STUDI SAINS DATA
FAKULTAS ILMU KOMPUTER
UPN "VETERAN" JAWA TIMUR

2026

Prakiraan Laju Minyak 30–90 Hari pada Lapangan Volve dengan XGBoost dan Explainable AI (TreeSHAP) Berbasis Edge AI: Perbandingan terhadap Decline Curve Analysis Arps

Kelompok 3 · Kasus 18: Prediksi Produksi dan Analisis *Decline Curve* Sumur *(Production Forecasting & DCA)*

Kode & dokumentasi: https://github.com/randizap/volve-dca-cockpit · Aplikasi web: https://kelompok3-volve.vercel.app

Abstrak — Prakiraan laju minyak jangka pendek menjadi dasar perencanaan produksi dan keputusan intervensi sumur, tetapi kurva penurunan Arps mengasumsikan operasi kontinu sehingga kurang andal ketika sumur mengalami *shut-in*. Penelitian ini memprakirakan rata-rata laju minyak 30, 60, dan 90 hari ke depan pada lima sumur produser lapangan Volve (Equinor) memakai XGBoost dengan 15 fitur *lag/rolling* (termasuk *uptime*, *water cut*, GOR, tekanan kepala sumur, *choke*, dan injeksi air lapangan), lalu membandingkannya dengan *persistence* dan Arps *hyperbolic*. Evaluasi memakai validasi *walk-forward* 2011–2016 dengan pelatihan ulang tahunan, sehingga setiap prakiraan hanya memakai data sebelum tahun uji (6.657 titik uji pada horizon 30 hari). XGBoost sendirian mencapai WAPE 25,1% pada horizon 30 hari dan tidak mengalahkan *persistence* (22,9%) maupun Arps (24,2%). Rata-rata bobot sama ketiga metode (prakiraan terpadu) memberi galat terendah di ketiga horizon (WAPE 20,5%, 20,2%, dan 20,2%). Rentang P90–P10 yang dikalibrasi dari galat historis mencakup 76–79% kenyataan (nominal 80%). TreeSHAP menunjukkan *uptime* 30 hari sebagai pendorong terbesar. Model dikonversi ke ONNX berukuran sekitar 91 KB per horizon (selisih maksimum terhadap XGBoost $2{,}1\times10^{-6}$) dan berjalan di peramban lewat onnxruntime-web dengan latensi median 0,022 ms per prakiraan, tanpa server maupun GPU.

Kata kunci: *decline curve analysis, XGBoost, walk-forward validation, TreeSHAP, Edge AI, ONNX, lapangan Volve.*

1. Pendahuluan

Prakiraan laju minyak per sumur untuk horizon bulanan menjadi masukan perencanaan *lifting*, alokasi fasilitas, dan keputusan intervensi seperti *workover* atau *infill drilling*. Metode yang paling lazim adalah *decline curve analysis* (DCA) Arps [1], yang mencocokkan kurva eksponensial, hiperbolik, atau harmonik pada riwayat laju. Metode ini mengasumsikan operasi berjalan kontinu; *shut-in*, perubahan *choke*, dan intervensi sumur memutus asumsi tersebut [8]. Pada data Volve yang dipakai di sini, 4% hingga 42% hari per sumur berlaju minyak nol, sehingga proyeksi Arps mudah menyimpang. Selisih prakiraan berimbas langsung pada **Pilar 2** (optimasi produksi dan *asset reliability*) dan **Pilar 3** (efisiensi biaya, OPEX/CAPEX) industri migas.

Literatur 2021 sampai 2026 bergeser ke DCA berbasis *machine learning* (ML-DCA). Li dkk. [2] mengusulkan metode *rescaling* untuk memperbaiki ML-DCA pada reservoir unkonvensional; Gu dkk. [3] memakai model sekuens *deep learning* untuk reservoir gas; Bhattacharyya dan Vyas [4] menerapkan ML untuk memprediksi penurunan laju minyak sumur *shale* Bakken; Chen dkk. [6] dan Mask dkk. [7] memadukan pengetahuan fisik kurva penurunan dengan jaringan saraf atau *transfer learning*. Pada Volve sendiri, Ng dkk. [5] menerapkan teknik ML dan algoritma metaheuristik untuk prakiraan produksi sumur. Studi terbaru [8] membandingkan Arps dengan ANN, SVM, dan regresi linear pada lapangan gas dan melaporkan ANN terbaik dengan data yang dibagi acak; penulisnya sendiri menyebut akurasi hampir sempurna itu mencerminkan keteraturan data.

Sebagian besar studi tersebut menyasar reservoir unkonvensional atau gas, berhorizon panjang (EUR), dan tidak membahas penyebaran model ke perangkat pengguna. Kami tidak membandingkan angka galat secara langsung dengan literatur karena dataset, horizon, dan metrik berbeda; literatur

dipakai sebagai landasan desain dan pembenar *baseline* Arps. Kontribusi proyek ini: (i) perbandingan Arps, *persistence*, XGBoost, dan kombinasinya pada data Volve asli dengan validasi *walk-forward* tahunan yang mencegah kebocoran data masa depan; (ii) fitur yang sadar interupsi (*uptime*, rasio laju terkini, dan injeksi air) dengan target relatif terhadap rata-rata 30 hari terakhir; (iii) rentang ketidakpastian P90–P10 yang dikalibrasi dari galat historis; (iv) model ONNX ringan yang berjalan di peramban; (v) penjelasan TreeSHAP dan analisis ekonomi *what-if* yang dikaitkan dengan keputusan intervensi. Batasan penelitian dibahas pada Subbab 3.6.

2. Metodologi

2.1 Dataset

Data berasal dari Volve Data Village (Equinor) [11], *sheet* Daily Production Data (15.634 baris, 24 kolom). Setelah difilter WELL_TYPE = OP tersisa 9.143 baris dari enam lubang sumur produser (Tabel 1). 15/9-F-4 hanya injektor sehingga tidak dipakai sebagai target; volume injeksinya dijumlahkan per hari sebagai fitur injeksi lapangan. 15/9-F-5 sebelumnya sumur injeksi dan hanya berproduksi 144 hari, sehingga dikeluarkan dari pelatihan dan metrik agregat. Kolom yang dipakai adalah ON_STREAM_HRS, AVG_WHP_P, AVG_CHOKE_SIZE_P, BORE_OIL_VOL, BORE_GAS_VOL, BORE_WAT_VOL, dan BORE_WI_VOL (Sm^3).

Tabel 1. Ringkasan data sumur produser dan jumlah titik uji *walk-forward* pada horizon 30 hari (hari kalender setelah reindeks).

Sumur	Periode	Hari	% hari minyak = 0	Tanggal hilang	Titik uji (H = 30)	Status
15/9-F-12	2008-02-12 s.d. 2016-09-17	3.141	9,7	85	2.035	latih & uji
15/9-F-14	2008-02-12 s.d. 2016-09-17	3.141	13,3	85	2.032	latih & uji
15/9-F-11	2013-07-08 s.d. 2016-09-17	1.168	3,9	4	1.078	latih & uji
15/9-F-15 D	2014-01-12 s.d. 2016-09-17	980	21,7	2	867	latih & uji
15/9-F-1 C	2014-04-08 s.d. 2016-04-21	745	42,4	1	645	latih & uji
15/9-F-5	2016-04-12 s.d. 2016-09-17	159	23,9	15	–	dikeluarkan
Total		9.334		192	6.657	

2.2 Pra-proses dan rekayasa fitur

Lima aturan pembersihan diterapkan: duplikat dibuang (tidak ada), 13 baris dengan jam operasi lebih dari 24 dipangkas ke 24, 4 baris bervolume negatif dinolkan, dan 1 baris dengan jam operasi nol tetapi minyak positif dibuang, menyisakan 9.142 baris. Setiap sumur lalu direindeks ke kalender harian penuh. Tanggal yang hilang (85 hari pada F-12 dan F-14, identik di kedua sumur) diisi nol; alternatifnya, yaitu mengabaikannya sebagai data hilang, hanya menggeser WAPE XGBoost dari 25,1% ke 24,7%, sehingga asumsi ini tidak mengubah kesimpulan. Nilai WHP dan *choke* yang kosong diisi maju-mundur (*ffill/bfill*). Lima belas fitur dihitung dari jendela *rolling* yang berakhir di hari t sehingga tidak memuat informasi masa depan: rasio laju (oil_m7_m30, oil_m30_m90, oil_d1_m30), *water cut* (wc7, wc_delta), GOR (log_gor7, gor_ratio), tekanan dan *choke* (whp7, whp_ratio, choke7), *uptime* (uptime7, uptime30), skala laju (log_m30), serta injeksi air lapangan (inj30, inj_ratio). Fitur umur sumur (log_days) dari rancangan awal dibuang karena membuat model menghafal identitas sumur (Subbab 3.2).

Target adalah rata-rata laju minyak hari t+1 sampai t+H untuk H = 30, 60, dan 90; satu model dilatih per horizon. Karena pohon keputusan tidak dapat mengekstrapolasi skala, model dilatih pada rasio target terhadap skala terkini, dipotong ke rentang [0, 3], lalu dikembalikan ke skala aslinya (arah normalisasi ini sejalan dengan *rescaling* pada [2]):

$$\hat{y}_t = f(x_t) \cdot (m30_t + 1), \quad \text{dengan } f \text{ dilatih pada } y_t / (m30_t + 1)$$

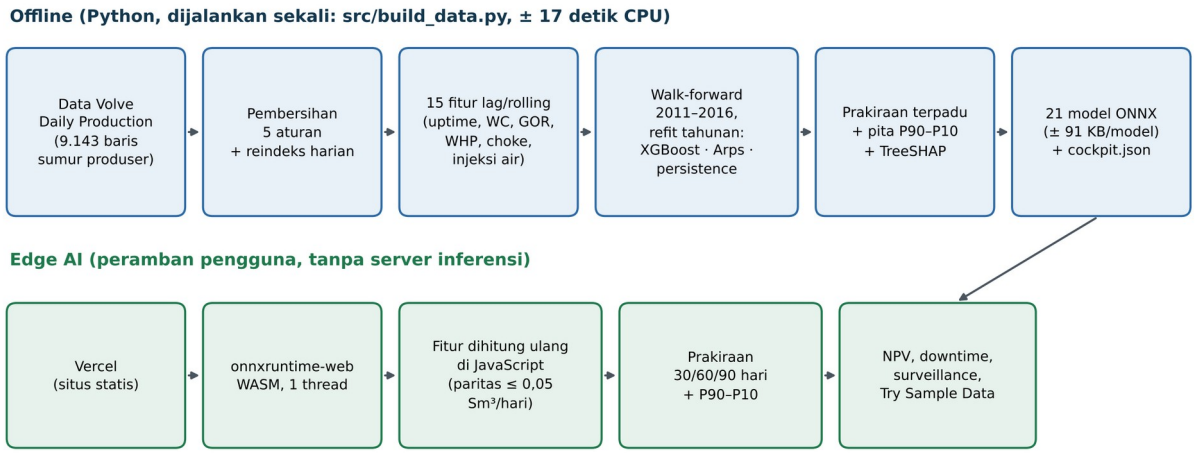
2.3 Model, baseline, dan skema evaluasi

XGBoost [9] regresi dengan 200 pohon, kedalaman 3, *learning rate* 0,05, *subsample* 0,8, *colsample_bytree* 0,8, *min_child_weight* 5, dan *seed* 0; parameter ditetapkan *a priori* tanpa *tuning*. *Baseline* pertama adalah *persistence* ($\hat{y}$ = m30). *Baseline* kedua adalah Arps *hyperbolic*, $q(t) = q_i/(1 + b \cdot D_i \cdot t)^{(1/b)}$ [1], yang di-*fit* ulang di setiap titik uji pada 180 hari terakhir (hanya hari berlaju positif) dengan pencarian *grid* 31 nilai $D_i \in [10^{-4}; 10^{-1}]$ × 21 nilai $b \in [0{,}02; 1]$ dan q_i dari regresi tertutup, lalu dirata-ratakan pada t+1 sampai t+H. Bila hari berlaju positif kurang dari 20, prakiraan Arps diganti m30. **Prakiraan terpadu** adalah rata-rata bobot sama dari XGBoost, Arps, dan *persistence*; bobotnya tidak dipelajari sehingga tidak menambah risiko *overfitting*.

Validasi bersifat *walk-forward*: untuk setiap tahun uji Y dari 2011 sampai 2016, model dilatih ulang hanya pada baris yang jendela targetnya selesai sebelum 1 Januari Y, lalu dipakai memprakirakan seluruh hari pada tahun Y. Setiap hari dengan m30 > 5 Sm³/hari dan riwayat minimal 60 hari menjadi titik uji (6.657 titik pada H = 30), dan semua metode dievaluasi pada titik yang sama. Generalisasi ke sumur baru diuji terpisah dengan *leave-one-well-out* (LOWO). Rentang ketidakpastian dibentuk dari kuantil 10% dan 90% galat logaritmik *out-of-fold* per horizon dan per rezim (*uptime*30 ≥ 0,85 normal, < 0,85 gangguan), lalu cakupannya diuji dengan kalibrasi *leave-one-year-out*. Metrik adalah MAE, RMSE (Sm³/hari), dan WAPE = $\Sigma|\hat{y} - y| / \Sigma y$. Karena masalah utamanya regresi, F1-score dan mAP tidak relevan; WAPE dipilih karena skala laju antarsumur berbeda beberapa kali lipat dan hari bernilai nol membuat MAPE tidak terdefinisi. PR-AUC dipakai untuk tugas turunan peringatan dini (Subbab 3.4).

2.4 Optimasi efisiensi dan arsitektur Edge AI

Setiap model dikonversi ke ONNX (onnxmltools, opset 15) dan dicek terhadap XGBoost native: 3 model final untuk data unggahan pengguna dan 18 model *walk-forward* (6 tahun × 3 horizon) untuk simulasi *hindcast*. Di web, onnxruntime-web (WASM, satu *thread*) memuat model sesuai kebutuhan dan menghitung prediksi di sisi klien. Kelima belas fitur dihitung ulang dalam JavaScript dari data mentah dan diuji paritasnya terhadap Python (selisih maksimum 0,05 Sm³/hari pada 351 titik × 3 horizon, setara presisi penyimpanan). Kontribusi TreeSHAP [10] dihitung *offline* dan disimpan bersama data. Aplikasi statis di-*deploy* ke Vercel; *runtime* WASM dan pustaka disajikan dari folder vendor dengan *cache* satu tahun (Gambar 1).



Gambar 1. Alur sistem dari data Volve hingga inferensi di peramban.

3. Hasil dan Pembahasan

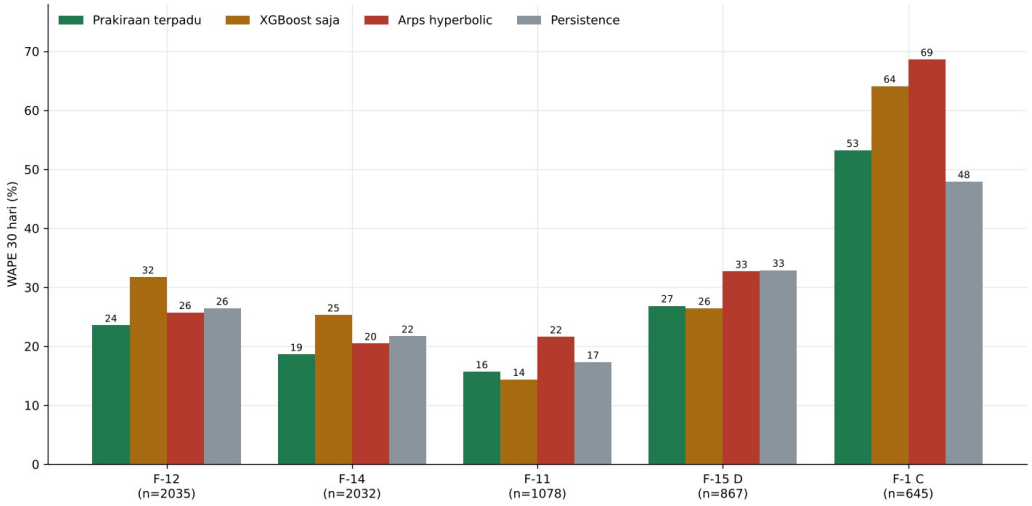
3.1 Performa prediksi

Tabel 2. WAPE prakiraan rata-rata laju minyak per horizon (*walk-forward* 2011–2016, tanpa F-5; n = 6.657, 6.530, dan 6.380 titik). Makin kecil makin baik.

Metode	WAPE 30 hari	WAPE 60 hari	WAPE 90 hari
Persistence (m30)	22,92%	25,48%	27,02%
Arps hyperbolic (fit 180 hari)	24,24%	24,15%	23,88%
Arps × uptime 30 hari	26,28%	27,45%	27,37%
XGBoost (15 fitur)	25,09%	24,32%	23,23%
Prakiraan terpadu (rata-rata ketiganya)	20,51%	20,21%	20,25%

Prakiraan terpadu memberi galat terendah di ketiga horizon, dengan MAE 112,4 Sm³/hari pada H = 30 dibanding 125,6 (*persistence*), 132,9 (Arps), dan 137,5 (XGBoost). XGBoost sendirian tidak lebih baik daripada *baseline* pada horizon 30 hari dan hanya unggul tipis atas Arps pada 90 hari. Gambar 4(b) menunjukkan penyebabnya: XGBoost buruk pada 2011–2013 (WAPE 39,1% pada 2012) ketika data latih baru berasal dari dua sumur, tetapi terbaik pada 2015–2016 (14,7% pada 2016) ketika data latih bertambah dan gangguan operasi makin sering, saat Arps justru memburuk (32,2% pada 2015). Kesalahan ketiga metode tidak searah sepenuhnya, sehingga rata-ratanya lebih stabil daripada metode mana pun. Versi awal penelitian ini melaporkan WAPE XGBoost 16,2% dari pemisahan 75/25 per sumur; protokol itu lebih longgar daripada *walk-forward* dan tidak dipakai lagi.

3.2 Hasil per sumur



Gambar 2. WAPE 30 hari per sumur (*walk-forward*); n adalah jumlah titik uji.

XGBoost terbaik pada F-11 (14,4%) dan F-15 D (26,4%), sedangkan prakiraan terpadu dan Arps lebih baik pada F-12 dan F-14 yang menyumbang 61% titik uji. F-1 C sulit bagi semua metode (WAPE terpadu 53,2%) karena sumur ini berhenti pada 42% hari. Pada kondisi normal (*uptime*30 ≥ 0,85; 4.557 titik) WAPE terpadu 17,1%, sedangkan pada kondisi sering berhenti (2.100 titik) 29,2%; semua metode memburuk pada rezim kedua. Uji LOWO, yaitu model dilatih tanpa sumur yang diuji, memberi WAPE XGBoost 13,5–25,3% pada empat sumur selain F-1 C (65,7%), sebanding dengan hasil *walk-forward*; protokol ini masih memakai data masa depan sumur lain sehingga hanya menguji generalisasi antarsumur. Ablasi fitur memakai 2011–2013 untuk memilih dan 2014–2016 untuk konfirmasi: membuang umur sumur dan menambah injeksi air menurunkan WAPE XGBoost dari 21,0% ke 19,0% pada periode konfirmasi. Membuang tekanan dan *choke* tampak lebih baik (24,3% vs

25,1%), tetapi baru terlihat setelah melihat kedua periode sehingga tidak diadopsi; *downhole pressure* tidak membantu.

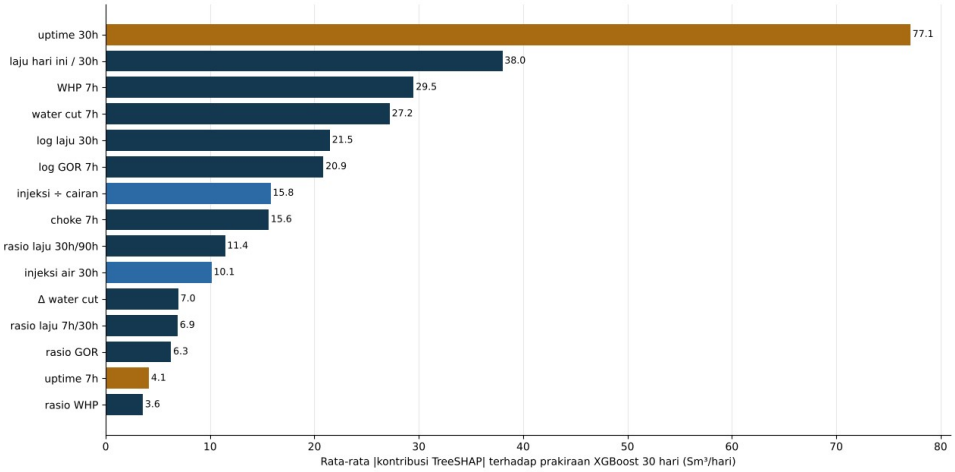
3.3 Efisiensi komputasi (Green AI)

Tabel 3. Metrik efisiensi model terhadap ketentuan Green AI.

Metrik	Hasil	Ketentuan / catatan
Ukuran model ONNX	± 91 KB per horizon (0,09 MB)	< 2 MB; 21 model total 1,9 MB, dimuat sesuai kebutuhan
Latensi median, ORT native (CPU)	0,006 ms	< 5 ms; onnxruntime 1.29, 1.000 pengulangan
Latensi median di peramban (WASM)	0,022 ms	< 5 ms; diukur di situs Vercel, rata-rata blok 50 prakiraan
Selisih maks. ONNX vs XGBoost	$2{,}1 \times 10^{-6}$	Paritas numerik terpenuhi
Selisih maks. fitur JavaScript vs Python	0,05 Sm³/hari	351 titik × 3 horizon; setara presisi penyimpanan
Runtime WASM (unduhan satu kali)	11,2 MB	Di-cache satu tahun; file terbesar repositori, jauh di bawah 100 MB
Server inferensi / GPU cloud	0	Inferensi di sisi klien

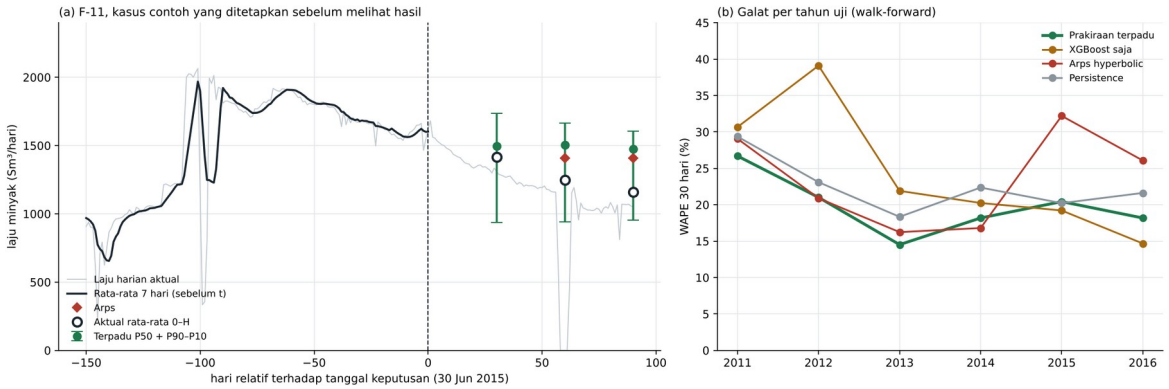
Model sangat ringan: 21 model hanya 1,9 MB total, dan peramban memuat tiga model (sekitar 270 KB) untuk satu tahun uji. Biaya unduhan terbesar ada pada *runtime* WASM (11,2 MB) yang diunduh sekali dan di-*cache* oleh peramban. Latensi di peramban diukur sebagai rata-rata blok 50 prakiraan karena pewaktu peramban terlalu kasar untuk mengukur satu prakiraan. Pelatihan dan seluruh validasi selesai sekitar 17 detik di CPU tanpa GPU.

3.4 Explainable AI



Gambar 3. Rata-rata |kontribusi TreeSHAP| global per fitur pada titik uji *walk-forward* (oranye: *uptime*; biru: injeksi air).

Rata-rata |SHAP| tertinggi dimiliki uptime30 (77,1 Sm³/hari, 26% dari total), disusul oil_d1_m30 (38,0), whp7 (29,5), wc7 (27,2), log_m30 (21,5), dan log_gor7 (20,9); kedua fitur injeksi air bersama-sama menyumbang 9%. Dominasi *uptime* sejalan dengan data: setelah periode berhenti, sumur cenderung pulih dari basis rendah, pola yang tidak tertangkap Arps. Namun ablasi menunjukkan fitur dengan SHAP besar belum tentu menurunkan galat (tekanan dan *choke* ber-SHAP besar tetapi tidak membantu), sehingga SHAP dibaca sebagai penjelasan perilaku model, bukan kausalitas fisik reservoir.



Gambar 4. (a) Prakiraan pada kasus contoh F-11, 30 Juni 2015, dengan rentang P90–P10; (b) WAPE 30 hari per tahun uji.

Kasus contoh F-11 pada 30 Juni 2015 ditetapkan sebelum hasil dilihat dan menjadi isi tombol Try Sample Data di aplikasi (Tabel 4). Prakiraan terpadu 1.498 Sm³/hari untuk 30 hari mendekati aktual 1.417 (galat 6%), tetapi pada 90 hari terlalu tinggi 27% (1.476 vs 1.162) karena laju turun lebih cepat daripada riwayatnya; aktual tetap berada di dalam rentang P90–P10 pada ketiga horizon. Satu kasus tidak membuktikan keunggulan, sehingga kasus ini dipakai untuk ilustrasi, bukan evaluasi.

Tabel 4. Kasus contoh *Try Sample Data* (F-11, 30 Juni 2015; *persistence* = 1.608 untuk semua horizon); rata-rata laju minyak dalam Sm³/hari.

Horizon	Aktual	Terpadu P50	Rentang P90–P10	XGBoost	Arps
30 hari	1.417	1.498	938–1.737	1.476	1.411
60 hari	1.247	1.505	941–1.667	1.498	1.409
90 hari	1.162	1.476	954–1.607	1.414	1.407

Cakupan rentang P90–P10 pada kalibrasi *leave-one-year-out* adalah 78,5%, 77,0%, dan 76,0% untuk 30, 60, dan 90 hari, sedikit di bawah nominal 80%, sehingga rentang ini sebaiknya dibaca sebagai batas bawah ketidakpastian. Untuk peringatan dini penurunan produksi (laju 30 hari ke depan < 70% laju 30 hari terakhir; prevalensi 14,4%), skor dari prakiraan terpadu hanya mencapai PR-AUC 0,148, hampir sama dengan tebakan acak, sedangkan skor gabungan eksploratif dengan *uptime* 7 hari mencapai 0,227 (1,6× acak). Penyebab *shut-in* tidak tercatat di data, sehingga fitur ini diposisikan sebagai prioritas pemeriksaan, bukan alarm otomatis.

3.5 Reproduksibilitas

Seluruh angka laporan ini dihasilkan oleh satu skrip, src/build_data.py, yang membersihkan data, menjalankan validasi, mengekspor 21 model ONNX, dan menulis public/data/cockpit.json, yaitu berkas yang sama yang ditampilkan aplikasi web; dengan demikian angka laporan dan aplikasi identik. Skrip dijalankan dengan xgboost 3.4.1, pandas 3.0.2, dan onnxruntime 1.24.4, dan selesai sekitar 17 detik. Data mentah tidak disertakan di repositori karena lisensi Equinor; pengguna mengunduhnya sendiri ke data/raw/.

3.6 Keterbatasan

(1) **Statistik.** Satu *seed* tanpa selang kepercayaan; jendela target saling tumpang tindih sehingga titik uji tidak independen, dan selisih antarmetode belum diuji signifikansinya (misalnya dengan *bootstrap* blok).

(2) **Data.** Hanya lima sumur dari satu lapangan, dengan F-12 dan F-14 menyumbang 61% titik uji; generalisasi ke lapangan lain belum terbukti.

(3) **Asumsi.** Hiperparameter tidak di-*tuning*, Arps memakai *fallback* m30 pada sebagian titik, dan *grid* Arps kadang mencapai batasnya ($b = 1$, $D_i = 10^{-4}$), misalnya pada kasus contoh.

(4) **Ketidakpastian.** Rentang P90–P10 sedikit terlalu sempit (76–79% vs 80%) dan dikalibrasi lintas sumur, sehingga per sumur bisa lebih meleset.

(5) **Ekonomi.** Harga, OPEX, CAPEX, dan *uplift* intervensi pada aplikasi adalah asumsi pengguna, bukan data Volve; estimasi produksi tertunda bersifat heuristik dari jam operasi.

(6) **Metode.** Model inti adalah *gradient boosting* berbasis pohon, bukan jaringan saraf dalam; tidak ada tekanan reservoir, *material balance*, atau simulasi reservoir.

4. Analisis Dampak Operasional dan Estimasi Bisnis

Solusi ini menyasar **Pilar 2** (optimasi produksi): prakiraan 30 hari per sumur dipakai untuk perencanaan *lifting*, alokasi kapasitas, dan menentukan sumur prioritas intervensi. Pada **Pilar 3** (biaya), dampaknya dua: prakiraan yang lebih akurat mengurangi salah taksir volume yang menjadi dasar keputusan *workover* atau *infill*, dan Edge AI meniadakan sewa server inferensi maupun GPU *cloud* sekaligus menjaga data produksi tetap di perangkat pengguna. Pilar 1 (HSSE) tidak disasar.

Untuk memberi gambaran skala, Tabel 5 mengubah selisih MAE pada horizon 30 hari (Subbab 3.1) menjadi volume dan nilai per sumur per 30 hari. Asumsi: 1 Sm^3 = 6,2898 bbl dan harga minyak USD 60, 70, dan 80 per bbl (skenario ilustratif, bukan data Volve).

Tabel 5. Pengurangan galat volume prakiraan 30 hari per sumur oleh prakiraan terpadu (dari selisih MAE, H = 30).

Pembanding	Selisih MAE (Sm^3/hari)	Volume 30 hari (bbl)	USD @60	USD @70	USD @80
Terpadu vs Arps	20,48	3.865	232 rb	271 rb	309 rb
Terpadu vs persistence	13,21	2.493	150 rb	174 rb	199 rb

Angka pada Tabel 5 adalah pengurangan galat rata-rata volume prakiraan, bukan penghematan kas atau tambahan produksi; nilai ekonominya baru terwujud jika prakiraan yang lebih baik mengubah keputusan nyata, misalnya jadwal *workover* atau alokasi kapasitas. Aplikasi web melengkapinya dengan analisis *what-if*: profil produksi dari prakiraan terpadu diubah menjadi NPV, harga impas, dan sebaran Monte Carlo (4.000 simulasi) untuk intervensi sumur. Pada kasus contoh dengan asumsi ilustratif (harga USD 65/bbl, OPEX USD 15/bbl, CAPEX USD 10 juta, *uplift* 10%), NPV P50 sekitar USD 26,8 juta dan harga impas USD 25,9/bbl; angka ini menunjukkan cara kerja alat, bukan rekomendasi investasi. Galat rata-rata prakiraan terpadu masih 112 Sm^3/hari (sekitar 707 bbl/hari), sehingga model layak diposisikan sebagai pendapat kedua di samping DCA, bukan pengganti keputusan *engineer*.

Saran implementasi:

- (a) Jalankan model dalam mode bayangan (*shadow mode*) pada sumur aktif selama beberapa bulan dan bandingkan dengan DCA yang sudah dipakai.
- (b) Beri penanda khusus pada sumur dengan uptime30 di bawah 0,85, karena galat terbesar muncul pada sumur berinterupsi.
- (c) Perbaiki kalibrasi rentang ketidakpastian (mis. *conformal prediction* per sumur) dan uji signifikansi sebelum hasilnya dipakai untuk keputusan investasi.
- (d) Latih ulang secara berkala karena distribusi produksi bergeser seiring penuaan sumur.

5. Kesimpulan

Pada validasi *walk-forward* 2011–2016, XGBoost dengan 15 fitur sadar-interupsi sendirian tidak konsisten mengalahkan *persistence* dan Arps *hyperbolic* (WAPE 30 hari 25,1% vs 22,9% dan 24,2%),

tetapi rata-rata bobot sama ketiganya memberi galat terendah di semua horizon (WAPE sekitar 20%) dan paling stabil antartahun. Rentang P90–P10 hasil kalibrasi galat mencakup 76–79% kenyataan. Model hanya sekitar 91 KB per horizon, paritas dengan XGBoost terjaga, dan berjalan di peramban dengan latensi median 0,022 ms tanpa server, sehingga memenuhi ketentuan Green AI dan Edge AI. TreeSHAP menunjukkan model terutama memanfaatkan *uptime* dan rasio laju terkini. Langkah berikutnya adalah uji signifikansi, *tuning* hiperparameter dengan validasi waktu, kalibrasi ulang rentang per sumur, dan data biaya nyata dari operator.

Daftar Pustaka

[1] Arps, J.J. (1945). Analysis of decline curves. *Trans. AIME*, 160, 228–247. doi:10.2118/945228-G

[2] Li, B., Billiter, T.C., Tokar, T. (2021). Rescaling method for improved machine-learning decline curve analysis for unconventional reservoirs. *SPE Journal*, 26, 1759–1772. doi:10.2118/205349-PA

[3] Gu, S., Wang, J., Xue, L., Tu, B., Yang, M., Liu, Y. (2022). Deep-learning-based production decline curve analysis in the gas reservoir through sequence learning models. *Computer Modeling in Engineering & Sciences*, 131, 1579–1599. doi:10.32604/cmes.2022.019435

[4] Bhattacharyya, S., Vyas, A. (2022). Application of machine learning in predicting oil rate decline for Bakken shale oil wells. *Scientific Reports*, 12, 16154. doi:10.1038/s41598-022-20401-6

[5] Ng, C.S.W., Jahanbani Ghahfarokhi, A., Nait Amar, M. (2022). Well production forecast in Volve field: application of rigorous machine learning techniques and metaheuristic algorithm. *Journal of Petroleum Science and Engineering*, 208, 109468.

[6] Chen, M., Qu, Z., Liu, W., Tang, S., Shang, Z., Ren, Y., Han, J. (2024). Production prediction model of tight gas well based on neural network driven by decline curve and data. *Processes*, 12, 932. doi:10.3390/pr12050932

[7] Mask, G.M., Wu, X., Nicholson, C. (2025). Enhanced hydrocarbon production forecasting combining machine learning, transfer learning, and decline curve analysis. *Gas Science and Engineering*, 134, 205522. doi:10.1016/j.jgsce.2024.205522

[8] Jacota, D.-R., Popa, C.R., Tănase, M., Veres, C. (2026). Machine-learning algorithm and decline-curve analysis comparison in forecasting gas production. *Processes*, 14(5), 826. doi:10.3390/pr14050826

[9] Chen, T., Guestrin, C. (2016). XGBoost: a scalable tree boosting system. *Proc. 22nd ACM SIGKDD*, 785–794. doi:10.1145/2939672.2939785

[10] Lundberg, S.M., Erion, G., Chen, H., DeGrave, A., Prutkin, J.M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2, 56–67. doi:10.1038/s42256-019-0138-9

[11] Equinor (2018). *Volve Data Village: dataset produksi harian dan bulanan lapangan Volve.* Equinor ASA.

[12] Rezaeipour, A., Dabir, B., Ahmadi, M. (2023). Data-driven approach to dynamic uncertainty quantification of oil well production: decline curve analysis and hidden Markov model. *Geoenergy Science and Engineering*, 229, 212131. doi:10.1016/j.geoen.2023.212131

Lampiran A. Contribution Statement

Tabel A1 merinci peran, tanggung jawab, dan persentase kontribusi tiap anggota (total 100%).

Tabel A1. Pembagian peran dan kontribusi anggota Kelompok 3.

Nama (NPM)	Peran	Tanggung jawab	Kontribusi
Raditya Andiza Putro (23083010058)	Model Architect Specialist	Perancangan 14 fitur lag/rolling, pelatihan XGBoost dengan target rasio, baseline persistence dan Arps, evaluasi MAE, RMSE, dan WAPE	20%
Rosyidatul Kamila (23083010076)	Data & Pipeline Specialist	Akuisisi data Volve, pra-proses (reindeks kalender harian, pengisian WHP dan choke), pembagian temporal 75/25 dengan jeda 30 hari	20%
Pinka Nurdiana (23083010057)	Deployment & Edge Specialist	Konversi ONNX, uji paritas terhadap XGBoost, benchmark latensi, onnxruntime-web, deployment Vercel, manajemen GitHub	20%
Vivian Subiono (23083010065)	Frontend & UX Specialist	Desain dan pengembangan UI web, fitur Try Sample Data dan unggah data produksi, visualisasi prakiraan dan kontribusi TreeSHAP	20%
Nahda Hayu Hemalina (23083010066)	Technical Writer & Business Impact Analyst	Penyusunan laporan ilmiah, pengelolaan referensi, analisis dampak operasional dan estimasi bisnis (Pilar 2 dan 3), dokumentasi README	20%
Total			**100%**

Lampiran B. Artefak Proyek

- Repositori GitHub (publik): https://github.com/randizap/volve-dca-cockpit, berisi pipeline (src/build_data.py), data dan metrik (public/data/cockpit.json), 21 model ONNX, dan kode web.
- Aplikasi web: https://kelompok3-volve.vercel.app yang memuat inferensi di peramban, *Try Sample Data*, unggah data produksi, analisis investasi, dan tampilan TreeSHAP.
- Reproduksi: jalankan python run.py (atau src/build_data.py) setelah menaruh data Volve Data Village di data/raw/; skrip menghasilkan ulang cockpit.json dan seluruh model ONNX (Subbab 3.5).